RETHINKING ATTENTION WITH PERFORMERS

Jean Soler, Olivier Serris, Nicolas Castanet Sorbonne Université - M2 DAC



1 - Le problème de l'Attention

$$Attention(Q,K,V) = Softmax\Big(rac{QK^T}{\sqrt{d}}\Big)V$$

Complexité de calcul matricielle AB avec $A \in \mathbb{R}^{nm}$, $B \in \mathbb{R}^{mp}$: $\mathcal{O}(nmp)$

Dans l'attention, on a les matrices Querys, Keys et Values : $Q \in \mathbb{R}^{Ld}$, $K^T \in \mathbb{R}^{dL}$ et $V \in \mathbb{R}^{Ld}$

 $\int L$: taille des séquences (possiblement très grand !) d: dimension d'embedding




Fig. 1: complexité de calcul en fonction de l'ordre de la multiplication matricielle

 \Longrightarrow Le softmax force la complexité de calcul à être quadratique en L : $\mathcal{O}(L^2d)$

2 - Approximation du Softmax


Objectif: trouver Q' et K' tel que:

$$Q^{'}K^{'T}pprox Softmaxig(rac{QK^{T}}{\sqrt{d}}ig)$$

tel que

$$Attention(Q, K, V) pprox Q^{'}(K^{'T}V)$$

Réécriture du Softmax : $Softmax\Big(rac{QK^T}{\sqrt{d}}\Big) = D^{-1}A$ avec, $\begin{cases} A = exp(QK^T/\sqrt{d}) \\ D = diag(A1_L) \end{cases}$ $\Longrightarrow Attention(Q,K,V) = D^{-1}AV$



3 - Fonctions noyaux

On veut trouver une fonction noyaux ϕ telle que :

$$K_{SM}(x,y) = \exp{(xy^T)} = \phi(x)^T \phi(y)$$

En utilisant l'approximation du noyaux gaussien grâce aux features de fourriers, les auteurs de [1] trouvent :

$$egin{align} K_{SM}(x,y) &= \mathbb{E}_{w \sim \mathcal{N}(0,I_d)}[\exp{(-rac{||x||^2}{2})}\exp{(-rac{||y||^2}{2})}\exp{(w^Tx)}\exp{(w^Ty)}] \ \implies \phi(x) &= rac{1}{\sqrt{R}}\exp{(-rac{||x||^2}{2})}(\exp{(w_1^Tx)},...,exp(w_R^Tx)) \ \end{aligned}$$





Fig. 3: MSE loss entre l'approximation et le softmax selon le nombre de features (iid vs orthogonales), embedding dim d = 100

4 - Architecture du modèle



5 - Temps execution

Dans l'expérience suivante on étudie le temps d'exécution d'une passe (forward + backward) à travers une couche d'attention avec une seule tête.




Fig. 5: num Features R = 100, embedding dim d = 50

Sur des séquences de grandes tailles le performer permet d'améliorer la vitesse de calcul et/ou d'augmenter la taille du batch.

6 - Accuracy sur IMBD




Fig. 6: Courbe d'accuracy sur IMBD. (orange = transformer, bleu = performer) , num Features R = 100, embedding dim d = 50

Les performances d'un transformer VS un performer ne sont pas différentiables sur une base simple comme IMDB.

Pour le même nombre d'epoch l'apprentissage est 50% plus rapide chez le performer.

References

- [1] Krzysztof et al. Rethinking Attention with Performers ICLR 2021
- [2] Vaswani et al. Attention Is All You Need 2017
- [2] Yu et al. Orthogonal Random Features 2016
- [3] Rahimi et al. Random Features for Large-scale Kernel Machines